

Nom du groupe (tel qu'attribué sur IRIS) : **TD 3 M**

Nom des étudiants : **KHALDI Idir - MAHIOUT Riad - ONGLABAY Rasululla**

Date : **17/01/2025**

Table des matières

I. Évaluation du module Stanza	1
I.1. Message qui a été attribué au groupe et son analyse Stanza	2
I.2. La segmentation en phrases	3
I.3. La segmentation en tokens	3
I.4. L'étiquetage morpho-syntaxique	3
a. Evaluation globale	3
b. Etiquetage morpho-syntaxique des VERBES :	4
I.5. La lemmatisation	4
I.6. L'analyse syntaxique en relations de dépendance	5
a. Evaluation globale	5
b. Analyse syntaxique des relations Sujet :	5
II. Bilan de l'évaluation	5
III. Extraction d'information dans le corpus Cocorep-velo.txt	6
III.1. Description des données globales	6
III.2. Extraction d'information	6
a. Mots utilisés pour désigner un vélo :	7
b. Types de vélo mentionnés	7
c. Script conçu pour réaliser l'extraction	7
d. Propositions d'amélioration	7

Index des tableaux

Tableau 1: Version verticalisée et corrigée du message <#https ://hgkjgkjg>	2
Tableau 2: xx	3
Tableau 3: xx	3
Tableau 4: xx	3
Tableau 5: xx	4
Tableau 6: xx	4
Tableau 7: xx	4
Tableau 8: xx	4
Tableau 9: xx	4
Tableau 10: xx	5
Tableau 11: Aperçu quantitatif du corpus	6
Tableau 12: mots utilisés pour désigner un vélo et leur fréquence	7
Tableau 13: Termes désignant les types de vélo mentionnés dans le corpus	7

I. Évaluation du module Stanza

Cette partie concerne l'évaluation de l'efficacité des modules de traitements automatique du langage proposés par Stanza.

L'évaluation portera sur un seul texte du corpus dont l'identifiant a été attribué à votre groupe (voir l'attribution dans le tableur disponible dans les fichiers déposés sur IRIS).

Pour chaque niveau d'analyse, l'évaluation consiste à

- 1. identifier les erreurs commises par l'analyseur*
- 2. calculer les mesures de précision et, dans certains cas, les mesures de rappel (pour*

- certaines modules, seule la précision est calculable).*
- commenter les erreurs observées et les classer par catégories, en vous appuyant autant que possible sur des caractéristiques linguistiques telles que vues au cours de votre formation (parties du discours, relations syntaxiques, etc.) et énoncées en cours : *ambiguïté, variation, évolutivité et implicite du langage naturel. Si pour certains niveaux vous n'observez aucune erreur, l'indiquer explicitement.*
 - conclure en indiquant quel est selon vous le meilleur outil (en fonction des scores de précision et rappel ET de la « gravité » des erreurs observées).

I.1. Message qui a été attribué au groupe et son analyse Stanza

Identifiant du message : <<https://www.commentreparer.com/66638/Velo/velo-eliptique-proform-pas-de-resistance>>

Texte du message : Bonjour, Monsieur Madame, J'ai un velo elitique proform modele prevel 75008.0 serie w13n00138. Je n'ai plus de résistance, j'ai démonté le moteur de résistance. Est ce que cela peut être ça la panne, ou il y aurait d'autre possibilité de panne Je souhaiterais commander la pièce mais j'aimerais être sur. Pour info au niveau de la console tout fonctionne sauf la dureté de la poulie. Vous remerciant par avance de la réponse que vous pourrez me faire. Mon adresse mail est la suivante: thierryolympie@hotmail.fr Vous en souhaitant bonne réception. Cordialemnt
Thierry OLYMPIE

Insérez ici un tableau correspondant à la version verticalisée du message dans lequel toutes cellules présentant une erreur d'analyse sera colorée en rouge avec, dans la dernière colonne, votre proposition de correction (merci de suivre le modèle donné en exemple ci-dessous)

num	token	lemme	POS	Num (lemme) gouverneur	Relation syntaxique	Erreur(s) détectée(s)					
						p hr	tok	lem	POS	gouv	rel
#PHR1 : Bonjour, Monsieur Madame, J'ai un velo elitique proform modele prevel 75008.0 serie w13n00138.											
1	Bonjour	bonjour	INTJ	7(ai)	discourse						
2	,	,	PUNCT	1(Bonjour)	punct						
3	Monsieur	Monsieur	NOUN	7(ai)	conj						
4	Madame	monsieur	NOUN	3(Monsieur)	nmod					7(ai)	conj
5	,	.	PUNCT	3(Monsieur)	punct						
6	J'	moi	PRON	7(ai)	nsubj			je			
7	ai	avoir	VERB	0(.)	root						
8	un	un	DET	9(velo)	det						
9	velo	velo	NOUN	7(ai)	obj						
10	elitique	elitique	X	9(velo)	nmod		elliptique	elliptique	ADJ		amod
11	proform	proform	X	9(velo)	Flat:foreign				PROPN		nmod
12	modele	modele	X	9(velo)	Flat:foreign				NOUN		nmod
13	prevel	prevel	X	9(velo)	nmod				PROPN		
14	75008.0	75008.0	NUM	15(serie)	Obl:mod						
15	serie	serie	NOUN	7(ai)	nmod						
16	w13n00138	w13n00138	X	15(serie)	nmod				PROPN		
17	.	.	PUNCT	7(ai)	punct						
#PHR2 : Je n'ai plus de résistance, j'ai démonté le moteur de résistance.											
1	je	moi	PRON	3(ai)	nsubj			je			
2	n'	ne	ADV	3(ai)	advmod						
3	ai	avoir	VERB	0 (.)	root						
4	plus	plus	ADV	3 (ai)	advmod						
5	de	un	det	6 (résistance)	det			de			
6	résistance	résistance	NOUN	3 (ai)	obj						

7	,	,	PUNCT	10 (démonté)	punct								
8	J'	moi	PRON	10 (démonté)	nsubj			je					
9	ai	avoir	AUX	10 (démonté)	aux:tens								nmod
10	démonté	démonter	VERB	3 (ai)	conj								Root
11	le	le	DET	12 (moteur)	det								
12	moteur	moteur	NOUN	10(démonté)	obj								
13	de	de	ADP	14(résistance)	case								
14	résistance	résistance	NOUN	12(moteur)	nmod								
15	.	.	PUNCT	3(ai)	punct								
#PHR3 : Est ce que cela peut être ça la panne, ou il y aurait d'autre possibilité de panne													
1	Est	être	AUX	5 (peut)	cop								
2	ce	ce	PRON	5 (peut)	expl:subj								
3	que	que	PRON	5 (peut)	mark								
4	cela	cela	PRON	5 (peut)	nsubj								
5	peut	pouvoir	VERB	0 (.)	root								
6	être	être	AUX	7 (ça)	cop								
7	ça	ça	PRON	5 (peut)	xcomp								
8	la	le	DET	9 (Panne)	det								
9	panne	panne	NOUN	5 (peut)	xcomp								obj
10	,	,	PUNCT	14 (aurait)	punct								
11	ou	ou	CCONJ	14 (aurait)	cc								
12	il	lui	PRON	14 (aurait)	expl:subj			il					
13	y	y	PRON	14 (aurait)	expl:comp								
14	aurait	avoir	VERB	5 (peut)	conj								
15	d'	un	DET	17(possibilité)	det			de					
16	autre	autre	ADJ	17(possibilité)	amod								
17	possibilité	possibilité	NOUN	14 (aurait)	obj								
18	de	de	ADP	19(panne)	case								
19	panne	panne	NOUN	17 (possibilité)	nmod								
#PHR4 :Je souhaiterais commander la pièce mais j'aimerais être sûr.													
1	Je	moi	PRON	2(souhaiterais)	nsubj			je					
2	souhaiterais	souhaiter	VERB	0(.)	root								
3	commander	commander	VERB	2(souhaiterais)	xcomp								
4	la	le	DET	5 (pièce)	det								
5	pièce	pièce	NOUN	3(commander)	obj								
6	mais	mais	CCONJ	8(aimerais)	cc								
7	j'	moi	PRON	8(aimerais)	nsubj			je					
8	aimerais	aimer	VERB	2(souhaiterais)	conj								
9	être	être	AUX	10(sûr)	cop								
10	sûr	sûr	ADJ	8(aimerais)	xcomp								
11	.	.	PUNCT	2(souhaiterais)	punct								
#PHR5 : Pour info, au niveau de la console tout fonctionne sauf la dureté de la poulie.													
1	Pour	pour	ADP	2(info)	case								
2	info	info	NOUN	10(fonctionne)	obl:mod								
3	,	,	PUNCT	2(info)	punct								
4	au	à	ADP	5(niveau)	case								
5	niveau	niveau	NOUN	5(niveau)	obl								
6	de	de	ADP	10(fonctionne)	case								
7	la	le	DET	8(console)	det								
8	console	console	NOUN	8(console)	nmod								
9	tout	tout	PRON	5(niveau)	nsubj								

10	fonctionne	fonctionner	VERB	0(.)	root								
11	sauf	sauf	ADP	13(dureté)	case								
12	la	le	DET	13(dureté)	det								
13	dureté	dureté	NOUN	10(foctionne)	nmod								
14	de	de	ADP	16(poulie)	case								
15	la	le	DET	16(poulie)	det								
16	poulie	poulie	NOUN	13(dureté)	nmod								
17	.	.	PUNCT	10(fonctionne)	punct								
#PHR6: Vous remerciant par avance de la réponse que vous pourrez me faire.													
1	Vous	vous	PRON	2(remerciant)	nsubj								dobj
2	remerciant	remercier	VERB	0(.)	root								
3	par	par	ADP	4(avance)	case								
4	avance	avance	NOUN	2(remerciant)	obl								
5	de	de	ADP	7(réponse)	case								
6	la	le	DET	7(réponse)	det								
7	réponse	réponse	NOUN	2(remerciant)	obl:arg								
8	que	que	PRON	12(faire)	obj								
9	vous	vous	PRON	10(pourrez)	nsubj								
10	pourrez	pouvoir	VERB	7(réponse)	acl:relcl								
11	me	moi	PRON	12(faire)	obj				me				
12	faire	faire	VERB	10(pourrez)	xcomp								
13	.	.	PUNCT	2(remerciant)	punct								
#PHR7: Mon adresse mail est la suivante : thierryolympie@hotmail.fr													
1	Mon	son	DET	2(adresse)	det				mon				
2	adresse	adresse	NOUN	6(suivante)	nsubj								
3	mail	mail	NOUN	2(adresse)	nmod								
4	est	etre	AUX	6(suivante)	cop						0(.)	root	
5	la	le	DET	6(suivante)	det								
6	suivante	suivante	NOUN	0(.)	root				ADJ	6(suivante	attr		
7	:	:	PUNCT	8	punct								
8	thierryolympie@hotmail.fr	thierryolympie@hotmail.fr	NOUN	6(suivante)	appos								
#PHR8 : Vous en souhaitant bonne réception.													
1	Vous	vous	PRON	3(souhaitant)	nsubj								
2	en	en	PRON	5(réception)	nmod						3(souhaitant	obl:arg	
3	souhaitant	souhaiter	VERB	0(.)	root								
4	bonne	bon	ADJ	5(réception)	amod								
5	réception	réception	NOUN	3(souhaitant)	obj								
6	.	.	PUNCT	3(souhaitant)	punct								
#PHR9 : Cordialemnt Thierry OLYMPIE.													
1	Cordialemnt	Cordialemnt	PROPN	0(.)	root			cordialement	cordial ement	ADV			
2	Thierry	Thierry	PROPN	1(Cordialemnt	flat:name								
3	OLYMPIE	OLYMPIE	PROPN	2(Thierry)	flat:name								

Tableau 1: Version verticalisée et corrigée du message <#https ://hgkjgkig>

I.2. La segmentation en phrases

		Stanza		
	Nb. de caractères...	...de fin de phrase	...de non fin de phrase	Total
Référence (vous)	...de fin de phrase	8	1	9
	...de non fin de phrase	0	0	0
	<i>Total</i>	8	1	9

Tableau 2: xx

Calcul de la précision et du rappel de la segmentation en phrase :

$$P = \frac{8}{8} = 1 = 100\%$$

$$R = \frac{8}{9} = 0,89 = 89\%$$

Commentaires sur les erreurs observées :

Phrase concernée : Phrase 1 ("Codrialement Thierry OLYMPIE").

Stanza a identifié la comme une seule phrase a cause d'absence de caractère de ponctuation

Mais je la considère comme une formule de salutation et doit être séparé vu que la phrase suivante est un nom propre .

Codrialement

Thierry OLYMPIE

I.3. La segmentation en tokens

		Stanza		
	Nb. de caractères...	...de fin de token	...de non fin de token	Total
Référence (vous)	...de fin de token	109	0	109
	...de non fin de token	0	0	0
	<i>Total</i>	109	0	109

Tableau 3: xx

Calcul de la précision et du rappel de la segmentation en tokens:

$$P = \frac{109}{109} = 1 = 100\%$$

$$R = \frac{109}{109} = 1 = 100\%$$

Commentaires sur les erreurs observées :

Aucune erreur détectée .

I.4. L'étiquetage morpho-syntaxique

a. Evaluation globale

	nb. de mots	nb. de mots correctement étiquetés morphosyntaxiquement	Précision globale
Stanza	109	102	93,6%

Tableau 4: xx

Commentaires sur les erreurs observées :

Phrase 2 :

tokens : 5,6,7,8,11

Phrase 8 :

token : 6

Phrase 10 :

token : 1

b. Etiquetage morpho-syntaxique des VERBES :

Pour cette évaluation, on considère que les VERBES sont les mots étiquetés VERB et AUX.

Liste des verbes selon vous : ai, être, est, avoir, peut, être, aurait, souhaiterais, commander, aimerais, être, fonctionne, remerciant, pourrez, faire, est, souhaitant.

		Stanza		
	Nb. de mots ...	où pos = VERB AUX	où pos ≠ VERB AUX	Total
Référence (vous)	où pos = VERB AUX	16	1	17
	où pos ≠ VERB AUX	1	91	92
	Total	17	92	109

Tableau 5: xx

Calcul de la précision et du rappel de l'étiquetage des verbes :

$P = 16/17 = 0,941 = 94,1\%$

$R = 16/17 = 0,941 = 94,1\%$

Commentaires sur les erreurs observés :

- Le token "est" dans "Mon adresse mail est la suivante" a été incorrectement étiqueté comme VERB alors qu'il devrait être AUX
- Le token "suivante" a été étiqueté comme NOUN alors qu'il devrait être un ADJ

Malgré ces erreurs, la performance globale reste très bonne avec une précision et un rappel supérieur à 94%, on peut dire que Stanza gère bien l'étiquetage des verbes dans l'ensemble.

I.5. La lemmatisation

	nb. de mots	nb. de mots correctement lemmatisés	Précision
Stanza	109	97	88,99%

Tableau 6: xx

Commentaires sur les erreurs observées :

Les erreurs les plus fréquentes sont observées avec les token suivants :

«Je» «de» «il» «me» «mon»

I.6. L'analyse syntaxique en relations de dépendance

a. Evaluation globale

	nb. de mots	nb. de mots avec le bon gouverneur	Précision
Stanza	109	105	96,3%

Tableau 7: xx

Commentaires sur les erreurs observées :

Phrase 1 : token 4

Phrase 7 : token 4 + token 6

Phrase 8 : token 5

b. Analyse syntaxique des relations Sujet :

		Stanza		
	Nb. de mots ...	où dep = nsubj	où dep ≠ nsubj	Total
Référence (vous)	où dep = nsubj	10	0	10
	où dep ≠ nsubj	1	98	99
	Total	11	98	109

Tableau 8: xx

Calcul de la précision et du rappel de l'étiquetage des relations sujets :

P = $10/11 = 0,90 = 90\%$

R = $10/10 = 1 = 100\%$

Commentaires sur les erreurs observées :

Précision pas mal !

II. Bilan de l'évaluation

	Stanza	
	Précision (P)	Rappel (R)
Segmentation en phrases	100%	89%
Segmentation en tokens	100%	100%
Étiquetage morphosyntaxique	93,6%	
Étiquetage des verbes		
Lemmatisation	88,99%	
Analyse des relations de dépendance syntaxique	96,3%	
Analyse des relations sujet	90%	100%

Tableau : Bilan de l'évaluation Stanza

Selon vos observations des erreurs et les scores obtenus, que pensez-vous des performances du

module Stanza ?

III. Extraction d'information dans le corpus Cocorep-velo.txt

III.1. Description des données globales

Nombre de textes :

Cette partie consiste à donner un aperçu quantitatif des unités linguistiques contenues dans le corpus selon l'analyse proposée par Stanza.


	Analyse Stanza
Nombre de phrases	9
Nombre moyen de phrases par message	9,00
Nombre de mots	109
Nombre moyen de mots par phrase	12,11
Nombre de noms communs (pos = NOUN)	23
Lemmes des 5 noms communs les plus fréquents	<i>monsieur</i> (2) <i>resistance</i> (2) <i>Panne</i> (2) <i>Moteur</i> (1) <i>piece</i> (1)
Nombre d'adjectifs (pos = ADJ)	3
Lemmes des 5 adjectifs les plus fréquents	<i>autre</i> (1) <i>bon</i> (1) <i>sur</i> (1)
Nombre de verbes (pos = VERB AUX)	18
Lemmes des 5 verbes les plus fréquents	<i>avoir</i> (4) <i>etre</i> (4) <i>pouvoir</i> (2) <i>Souhaiter</i> (1) <i>Démonter</i> (1)
Couple NOUN-VERB le plus fréquent tel que : 	<i>NOUN</i> ← <i>nsubj</i> ← <i>VERB</i> (fréquence)

Tableau 9: Aperçu quantitatif du corpus

III.2. Extraction d'information

Pour commencer, vous devez extraire les mots référant à un vélo (sous toutes ses formes y compris les mots mal orthographiés e.g. Veyllo ou les termes équivalents bicyclette, etc.), puis extraire les noms ou adjectifs qui viennent compléter ces mots en suivant les relations de dépendance syntaxique. Exemples : « vélo elliptique techness se400 », « velo d'appartement domyos vm 630 »...

Vous êtes ensuite libres de peaufiner votre script pour avoir une extraction plus fine, des contextes plus complets, plus diversifiés, ou fournir la fréquence des couples extraits.

Cette extraction doit se faire sur l'ensemble du corpus.

a. **Mots utilisés pour désigner un vélo :**

Mot	Catégorie motphosyntaxique (POS)	Fréquence
velo	NOUN	1
eliptique	ADJ	1
bicyclette	PROP	1

Tableau 10: mots utilisés pour désigner un vélo et leur fréquence

b. **Types de vélo mentionnés**

Terme (ex de phrase ou extrait de phrase)	Fréquence
velo eliptique proform modele prevel 75008.0	1

Tableau 11: Termes désignant les types de vélo mentionnés dans le corpus

c. **Script conçu pour réaliser l'extraction**

```
import stanza

class VeloExtractor:

    def __init__(self):

        # initialise le pipeline Stanza pour analyser le texte
        self.nlp = stanza.Pipeline('fr', processors='tokenize,pos')

        # liste des mots qui désignent un vélo
        self.base_terms = ['velo', 'vélo', 'bicyclette', 'bike', 'byciclette', 'cycle', 'cyclette']

    def is_velo_term(self, word):

        # vérifie si un mot correspond à un terme pour vélo
        return word.lower() in self.base_terms

    def extract_velo_mentions(self, text):

        # compte combien de fois chaque terme pour velo apparaît dans le texte
```

```

doc = self.nlp(text)
mentions = {}
for sentence in doc.sentences:

    for word in sentence.words:

        if self.is_velo_term(word.text):
            if word.text in mentions:
                mentions[word.text] += 1
            else:
                mentions[word.text] = 1

return mentions

```

```

def extract_velo_types(self, text):

```

```

    # types de vélos
    doc = self.nlp(text)
    velo_types = []
    for sentence in doc.sentences:
        for word in sentence.words:
            if self.is_velo_term(word.text):
                modifiers = []
                for other_word in sentence.words:
                    if other_word.head == word.id and other_word.deprel in ['amod', 'nmod',
'flat:name']:
                        modifiers.append(other_word.text)
                if modifiers:
                    velo_types.append((word.text + ' ' + ' '.join(modifiers), sentence.text))

    return velo_types

```

```

def analyze_text(self, text):

```

```

    # analyse le texte, cherche a trouver les mentions et types de vélos
    mentions = self.extract_velo_mentions(text)
    types = self.extract_velo_types(text)

```

```

    print("Mentions de vélos trouvées :")
    for term, count in mentions.items():
        print(f"- {term}: {count} occurrence(s)")

```

```

    print("\nTypes de vélos identifiés :")
    for velo_type, context in types:
        print(f"- Type: {velo_type}")
        print(f"  Contexte: {context}\n")

```

```

# Texte

```

```

text = """
Bonjour, Monsieur Madame,
J'ai un velo elitique proform modele prevel 75008.0 serie w13n00138.
Je n'ai plus de résistance, j'ai démonté le moteur de résistance.

```

Est ce que cela peut être ça la panne, ou il y aurait d'autre possibilité de panne
Je souhaiterais commander la pièce mais j'aimerais être sur.
Pour info au niveau de la console tout fonctionne sauf la dureté de la poulie.
Vous remerciant par avance de la réponse que vous pourrez me faire.
Mon adresse mail est la suivante: thierryolympie@hotmail.fr
Vous en souhaitant bonne réception.
Cordialemnt
Thierry OLYMPIE
""""

```
extractor = VeloExtractor()  
extractor.analyze_text(text)
```

d. Propositions d'amélioration

Le script actuel est une bonne base pour l'extraction d'information, mais il pourrait être amélioré pour mieux répondre aux besoins de l'analyse :

Détection :

- Corriger les fautes d'orthographe.
- Identifier les marques, modèles, types de vélos, et composants (ex. pédalier, dérailleur).

Analyse :

- Trouver les problèmes techniques et les pièces recherchées.
- Relier les problèmes aux composants.

Technique :

- Créer une interface pour afficher les résultats.
- Ajouter des tests pour vérifier le fonctionnement.

Données :

- Construire une base avec marques, modèles, synonymes, et termes techniques.

Extensions :

- Analyser les sentiments des utilisateurs.
- Produire des statistiques et rapports automatiques.